# Материалы и методы

## Описание набора данных

В работе использовался открытый набор данных пациентов с плоскоклеточным раком ротоглотки, подготовленный рабочей группой MICCAI и Онкологического центра им. М. Д. Андерсона (MD Anderson Cancer Center) по количественной визуализации опухолей головы и шеи [1]. Набор включает ретроспективные обезличенные данные пациентов, получавших в этом центре в 2005–2012 гг. радикальную лучевую терапию с модуляцией интенсивности (intensity-modulated radiation therapy, IMRT). Использовалась версия набора для соревнования по прогнозированию локального рецидива [2], распространяемая в формате NIfTI.

Согласно описанию авторов, включались пациенты с гистологически подтверждённым плоскоклеточным раком ротоглотки и известным статусом вируса папилломы человека (ВПЧ), без предшествующего хирургического лечения, с наблюдением более двух лет и с компьютерной томографией (КТ) с контрастированием до начала лечения. Исключались пациенты без пригодной КТ: без контрастирования, с артефактами от пломб в области интереса, выполненной после индукционной химиотерапии или биопсии. В статье итоговая выборка составляет 288 пациентов, однако распространяемая версия содержит 315 пациентов (150 в обучающей и 165 в тестовой части). Она соответствует этапу до исключения 9 возможных дубликатов и 18 случаев с некорректной маской опухоли.

В итоговую таблицу вошли 298 пациентов (140 обучающей и 158 тестовой части, рис. 1). 17 пациентов исключены из-за отсутствия маски первичной опухоли, без которой признаки опухоли рассчитать невозможно. Маска лимфоузлов имеется у 253 из 298 пациентов, и её отсутствие не являлось критерием исключения.

Единственная модальность — КТ головы и шеи с внутривенным контрастированием, выполненная преимущественно на томографах GE LightSpeed с матрицей $512 \times 512$. Размер вокселя в плоскости среза составляет 0,39–0,84 мм, толщина среза — 0,39–5,0 мм (медиана 1,0 мм).

Клиническая таблица содержит 18 переменных: наличие локального рецидива (1 или 0), демографические данные (пол, возраст на момент диагноза, раса), характеристики опухоли (сторона, подобласть ротоглотки, категории T и N и стадия по 7-му изданию классификации Американского объединённого комитета по раку, AJCC, степень дифференцировки), анамнез курения (статус и пачко-годы), параметры лечения (длительность курса облучения, суммарная доза, число фракций, индукционная и одновременная химиотерапия) и жизненный статус на момент последнего наблюдения (1 — жив, 0 — умер). Статус ВПЧ, упомянутый в описании набора, в таблицах отсутствует.

## Протокол извлечения радиомических признаков

Для каждого пациента доступны изображение КТ (`CT.nii.gz`) со значениями в единицах Хаунсфилда (HU) и маски в той же геометрии. Бинарная маска `GTVp.nii.gz` описывает макроскопический объём первичной опухоли (gross tumor volume, GTVp), маска `GTVn.nii.gz` — поражённые лимфоузлы (GTVn), причём каждый узел имеет собственную метку (1, 2, ...). Примеры приведены на рис. 2. Маски построены вручную двумя радиационными онкологами в VelocityAI 3.0.1 по диагностическим КТ согласно рекомендациям Международной комиссии по радиационным единицам и измерениям (ICRU, доклады 62 и 83) без доступа к клиническим данным и проверены третьим специалистом [1].

Признаки рассчитывались в PyRadiomics версии 3.1.1.dev111 [3] с чтением изображений через SimpleITK 2.5.6 [4]. Для первичной опухоли признаки считались по маске как есть. Для лимфоузлов все узлы объединялись в одну маску, и дополнительно сохранялось их число. Толщина среза различается между пациентами, а текстурные признаки чувствительны к разрешению [5], поэтому изображения приводились к изотропному вокселю $1 \times 1 \times 1$ мм (КТ — интерполяцией B-сплайном, маска — методом ближайшего соседа). Интенсивности дискретизировались с шагом 25 HU. Нормализация и фильтры не применялись, остальные настройки оставлены по умолчанию.

Рассчитывались все классы признаков PyRadiomics по исходному изображению — по 107 признаков для каждой маски (табл. 1), всего 215 признаков на пациента с учётом числа узлов. Итоговая таблица содержит 298 строк и 235 столбцов: идентификатор, часть набора, 18 клинических переменных и 215 признаков. У 45 пациентов без поражённых лимфоузлов признаки лимфоузлов не определены.

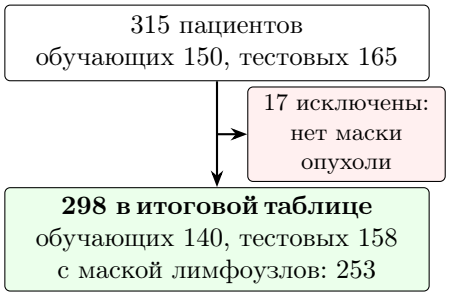



Рис. 1: Формирование итоговой выборки.

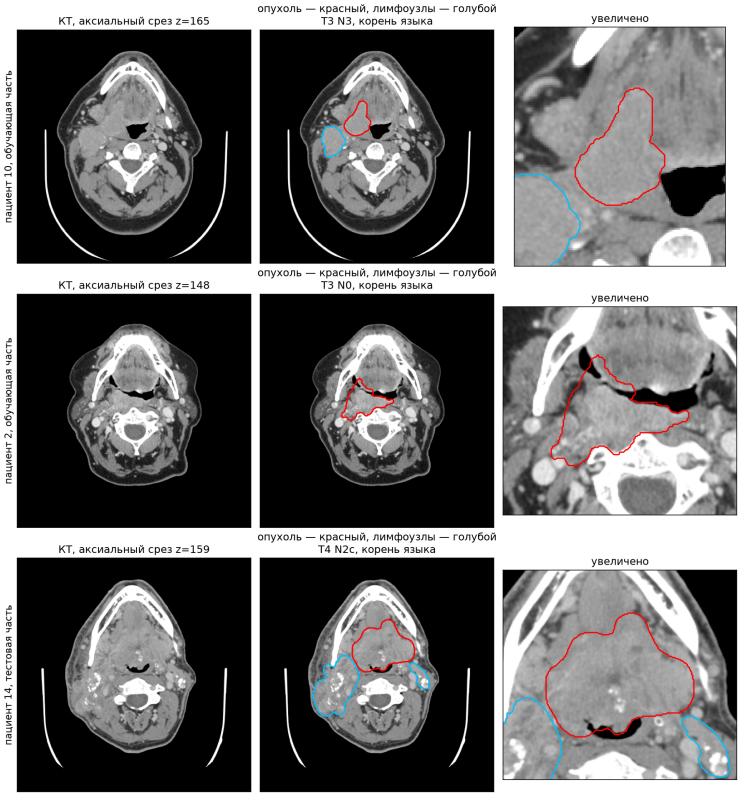



Рис. 2: Аксиальные срезы КТ трёх пациентов (10 и 2 — обучающая часть, 14 — тестовая) с контурами первичной опухоли (красный) и лимфоузлов (голубой). Показан срез с наибольшей площадью опухоли, справа — увеличенный фрагмент, окно 40/400 HU.

| Класс признаков | GTVp | GTVn |
|---|---|---|
| Форма (shape) | 14 | 14 |
| Первого порядка (first order) | 18 | 18 |
| Совпадения уровней серого (GLCM) | 24 | 24 |
| Длины серий (GLRLM) | 16 | 16 |
| Размеры зон (GLSZM) | 16 | 16 |
| Зависимости уровней серого (GLDM) | 14 | 14 |
| Разности соседних тонов (NGTDM) | 5 | 5 |
| Число узлов | — | 1 |
| **Всего** | **107** | **108** |

Таблица 1: Извлечённые группы радиомических признаков.

При контроле качества у трёх пациентов тестовой части выявлена нетипичная плотность внутри маски первичной опухоли (рис. 3): в маски пациентов 219 и 289 попадает просвет дыхательных путей, у пациента 257 контур частично лежит на кости.




Рис. 3: Пациенты с некорректными масками первичной опухоли (контур красным, окно 40/400 HU).

## Ссылки

[1] Hesham Elhalawani, Abdallah S. R. Mohamed, Aubrey L. White и др. «Matched computed tomography segmentation and demographic data for oropharyngeal cancer radiomics challenges». В: *Scientific Data* 4 (2017), с. 170077. DOI: 10.1038/sdata.2017.77.

[2] Amber Simpson и др. *Oropharynx Cancer (OPC) Radiomics Challenge :: Local Recurrence Prediction*. https://www.kaggle.com/competitions/opc-recurrence. Kaggle. 2016.

[3] Joost J. M. van Griethuysen, Andriy Fedorov, Chintan Parmar и др. «Computational radiomics system to decode the radiographic phenotype». В: *Cancer Research* 77.21 (2017), e104–e107. DOI: 10.1158/0008-5472.CAN-17-0339.

[4] Bradley C. Lowekamp и др. «The design of SimpleITK». В: *Frontiers in Neuroinformatics* 7 (2013), с. 45. DOI: 10.3389/fninf.2013.00045.

[5] Alex Zwanenburg, Martin Vallières, Mahmoud A. Abdalah и др. «The Image Biomarker Standardization Initiative: standardized quantitative radiomics for high-throughput image-based phenotyping». В: *Radiology* 295.2 (2020), с. 328–338. DOI: 10.1148/radiol.2020191145.