

Материалы и методы

Исход и момент применения модели

Модель предсказывает локальный рецидив первичной опухоли после радикальной лучевой терапии (ЛТ). Целевая переменная `Target_local_recurrence` равна 1, если за период наблюдения зарегистрирован рецидив в той же или иной подобласти ротоглотки, и 0, если рецидива не было. Значение перенесено без изменений из `Local_tumor_recurrence`, заполненной авторами набора по данным наблюдения (Elhalawani и др. 2017). Эта конечная точка выбрана потому, что локальный контроль – прямая цель облучения первичного очага.

В таблицах нет дат, длительности наблюдения и времени до рецидива, поэтому исход нельзя пересчитать на иной горизонт и он используется в форме, заданной организаторами. Горизонт задан критерием включения – наблюдением более двух лет (Elhalawani и др. 2017), покрывающим период, на который приходится основная часть локальных неудач после ЛТ. По критериям отбора все 128 пациентов без события наблюдались не меньше горизонта, однако индивидуально проверить это по таблице нельзя.

В анализ вошли 140 пациентов обучающей части (12 с рецидивом и 128 без него), 158 пациентов тестовой части без значения исхода исключены. Малое число событий – главное ограничение данных, требующее жёсткого ограничения числа признаков при моделировании (Riley и др. 2020).

Модель применяется после стадирования и утверждения плана лечения, до начала любой его части. К этому моменту известны диагностическая КТ, по которой построены маски `GTVp` и `GTVn`, демографические данные, анамнез курения, `TNM` и стадия, степень дифференцировки по биопсии, предписанные доза и фракционирование и решение о химиотерапии. Оценка риска при выбранном режиме позволяет обсуждать эскалацию дозы или более плотное наблюдение после ЛТ, раньше параметры лечения неизвестны, позже прогноз теряет практическую ценность. Поэтому как признаки нельзя использовать фактическую длительность курса `Radiation_treatment_course_duration`, зависящую от перерывов и известную лишь после окончания ЛТ, и жизненный статус `KM_Overall_survival_censor`, относящийся к периоду после лечения: это была бы утечка информации из будущего (Kaufman и др. 2012).

Первичный анализ данных

Использована итоговая таблица этапа извлечения признаков (298 пациентов, 235 столбцов: идентификатор, часть набора, 18 клинических переменных, число узлов `GTVn_n_nodes` и по 107 признаков `GTVp` и `GTVn`), исходный файл не изменялся. Для 14 категориальных переменных выведены все значения, для количественных – наименьшее и наибольшее, для клинических – в сравнении с допустимым диапазоном. Разных написаний одной категории и значений вне диапазонов нет, пропуски (NA, «не поддаётся оценке») записаны пустыми ячейками, а в `N_category` и `AJCC_Stage` встречается служебный код X («не может быть оценена»).

Значение заменялось верным, только если оно однозначно восстанавливается по другим полям записи, служебные коды и невозможные противоречия заменялись пропуском. Код X у одного пациента заменён пропуском в обеих переменных. У одного пациента при T4N1 указана стадия III, хотя по 7-му изданию AJCC при M0 категория T4 означает стадию IV (Edge и др. 2010), стадия выводится из T и N однозначно и исправлена. У 7 пациентов со статусом `Current` или `Former` указано 0 пачко-лет, что противоречит статусу, экспозицию восстановить нельзя, и значения заменены пропуском. Всего изменено 10 значений: 2 в `AJCC_Stage`, 1 в `N_category` и 7 в `Smoking_Pack-Years`.

Доза на фракцию (1,8–2,4 Гр) и число суток на фракцию (0,98–1,70, меньше единицы при облучении дважды в день) правдоподобны. Плотность ниже –1024 HU у 12 пациентов и выше 3071 HU у 5 объясняется выбросами B-сплайн-интерполяции и артефактами от стоматологических конструкций, не закрывавших опухоль (Elhalawani и др. 2017), это свойства вычисленных признаков, а не ошибки записи, и они сохранены. Маска `GTVn` отсутствует у 19 пациентов с N1–N3: по правилу авторов узлы не размечались, если КТ выполнена после эксцизионной биопсии узла (Elhalawani и др. 2017). У 2 пациентов с N0 маска `GTVn` есть, что противоречит тому же правилу, истинный статус узлов по таблице не восстановить, поэтому значения не исправлялись. Пациенты 219, 257 и 289 с погрешностями масок `GTVp` относятся к тестовой части и в анализ не вошли.

Пропуски есть в степени дифференцировки (43), пачко-годах (21: 14 исходных и 7 после исправления), расе, категории N и стадии (по 1), а также во всех 107 признаках `GTVn` у 45 пациентов, в `GTVp` пропусков нет. Пропуски `GTVn` приходятся ровно на пациентов с `GTVn_n_nodes` = 0, т.е. означают отсутствие узлов, а не потерю данных. В аналитической когорте доля про-

пусков составляет 11,4 % в степени дифференцировки, 7,1 % в пачко-годах и 14,3 % в GTVn. Переменная исключалась при доле пропусков выше 30 %, так как иначе её значения определялись бы в основном моделью заполнения – таких переменных нет.

Исключены идентификатор (сохранён как ключ), источник целевой переменной, служебная Fold, две недоступные в момент применения переменные и 2 дубликата: `firstorder_TotalEnergy` в обеих масках совпадает с `firstorder_Energy`, поскольку при вокселе 1 мм³ они отличаются лишь множителем (PyRadiomics community 2025). Констант нет. Добавлена вычисленная `Dose_per_fraction`, так как при равной суммарной дозе эффект облучения зависит от фракционирования.

Избыточность 218 количественных признаков сокращалась последовательным отбором: признак оставлялся, если модуль корреляции с каждым ранее оставленным не превышал 0,7, иначе исключался и засчитывался наиболее связанному оставленному. Порядок предпочтения не зависит от исхода: клинические признаки как доступные в рутинной практике, затем GTVp как область конечной точки, затем число узлов и GTVn,

внутри маски первыми идут объём (установленный прогностический фактор) и сферичность, далее порядок PyRadiomics. Использовалась ранговая корреляция Спирмена, так как распределения признаков сильно скошены и содержат выбросы плотности. Порог 0,7 (более половины общей ранговой дисперсии) выбран жёстким из-за малого числа событий. Корреляции считались по всем 298 пациентам без использования исхода, для GTVn – по 253 пациентам с узлами. Оставлен 41 признак (4 клинических, `GTVn_n_nodes`, 16 GTVp и 20 GTVn), исключено 177, наибольший модуль корреляции среди оставленных – 0,698. Больше всего признаков заменяют энтропия GTVn (32) и GTVp (26), минимальная плотность GTVp (25) и объём GTVp (23).

Аналитическая таблица содержит 140 пациентов, код пациента, целевую переменную и 52 признака: 11 категориальных и 41 количественный. Пропуски (16 в степени дифференцировки, 10 в пачко-годах, по 20 в признаках GTVn) на этом этапе не заполнялись, а связь признаков с исходом не изучалась, чтобы заполнение и отбор по исходу выполнять внутри кросс-валидации без оптимистичного смещения оценки.

Ссылки

- Edge, Stephen B. и Carolyn C. Compton (2010). «The American Joint Committee on Cancer: the 7th edition of the AJCC cancer staging manual and the future of TNM». В: *Annals of Surgical Oncology* 17.6, с. 1471–1474. DOI: 10.1245/s10434-010-0985-4.
- Elhalawani, Hesham, Abdallah S. R. Mohamed, Aubrey L. White и др. (2017). «Matched computed tomography segmentation and demographic data for oropharyngeal cancer radiomics challenges». В: *Scientific Data* 4, с. 170077. DOI: 10.1038/sdata.2017.77.

- Kaufman, Shachar и др. (2012). «Leakage in data mining: formulation, detection, and avoidance». В: *ACM Transactions on Knowledge Discovery from Data* 6.4, с. 15. DOI: 10.1145/2382577.2382579.
- PyRadiomics community (2025). *PyRadiomics documentation: radiomic features and customization of extraction*. URL: <https://pyradiomics.readthedocs.io>.
- Riley, Richard D., Joie Ensor, Kym I. E. Snell и др. (2020). «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368, с. m441. DOI: 10.1136/bmj.m441.

Словарь переменных и решений

Приведены все клинические и служебные переменные исходной таблицы, число узлов GTVn_n_nodes, вычисленная Dose_per_fraction, целевая переменная и оставленные радиомические признаки (16 из 107 для GTVp и 20 из 107 для GTVn) с числом исключённых признаков, которые каждый из них заменяет. Пропуски указаны после исправления значений во всей таблице (298 пациентов) и в аналитической когорте (140 пациентов), момент доступности – относительно применения модели после утверждения плана лечения.

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Patient_ID	код пациента, присвоенный при анонимизации, совпадает с именем папки снимков	целый, 1–315, уникален	служебная, всегда	0 / 0	оставить как ключ строки, не признак: идентификатор не несёт клинической информации
Fold	часть набора соревнования	категориальный: Training, Test	служебная, задана организаторами	0 / 0	исключить: служебная переменная
Local_tumor_recurrence	локальный рецидив первичной опухоли за период наблюдения	бинарный: 0, 1	после наблюдения не менее 2 лет	158 (53,0 %) / 0	исключить из признаков: источник целевой переменной
Gender	пол	категориальный: Male, Female	до начала лечения, при постановке диагноза	0 / 0	оставить
Age_at_diagnosis	возраст на момент диагноза, лет	целый, 30–89	до начала лечения, при постановке диагноза	0 / 0	оставить, заменяет 0 исключённых признаков
Race	раса	категориальный: White, Black, Hispanic, Asian, American_Indian/Alaska_Native	до начала лечения, при постановке диагноза	1 (0,3 %) / 0	оставить, пустая ячейка — пропуск, не заполнять
Tumor_side	латеральность опухоли	категориальный: L, R, Bilateral	до начала лечения, после стадирования	0 / 0	оставить
Tumor_subsite	подобласть ротоглотки	категориальный: BOT, Tonsil, GPS, Soft_palate, Pharyngeal_wall, Other	до начала лечения, после стадирования	0 / 0	оставить
T_category	категория T (AJCC 7)	порядковый: 1–4	до начала лечения, после стадирования	0 / 0	оставить
N_category	категория N (AJCC 7)	порядковый: 0, 1, 2a, 2b, 2c, 3	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить, служебный код X (1 значение) заменён пропуском
AJCC_Stage	стадия по AJCC 7, определяется T и N при M0	порядковый: I–IV	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить, X (1) заменён пропуском, III при T4N1 (1) исправлено на IV
Pathological_grade	степень дифференцировки опухоли	порядковый: I, I-II, II, II-III, III, IV	до начала лечения, по биопсии	43 (14,4 %) / 16 (11,4 %)	оставить, пропуски не заполнять, доля ниже порога 30 %
Smoking_status_at_diagnosis	статус курения на момент диагноза	категориальный: Never, Former, Current	до начала лечения, при постановке диагноза	0 / 0	оставить

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Smoking_Pack-Years	кумулятивное курение, пачко-лет	непрерывный, ≥ 0 , 0 только при Never	до начала лечения, при постановке диагноза	21 (7,0 %) / 10 (7,1 %)	оставить, 7 нулей при Current/Former заменены пропуском, заменяет 0 исключённых признаков
Radiation_treatment_course_duration	фактическая длительность курса ЛТ, дни	целый, 32–56	после окончания ЛТ	0 / 0	исключить: неизвестна в момент применения модели
Total_prescribed_Radiation_treatment_dose	суммарная предписанная доза, Гр	целый: 60, 63, 66, 70, 72	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить, заменяет 0 исключённых признаков
#_Radiation_treatment_fractions	число фракций	целый, 30–40	до начала ЛТ, при утверждении плана лечения	0 / 0	исключить: избыточна, $ \rho > 0,7$ с Dose_per_fraction
Induction_Chemotherapy	индукционная химиотерапия до ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
Concurrent_chemotherapy	химиотерапия одновременно с ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
KM_Overall_survival_censor	жизненный статус на последнем наблюдении	бинарный: 1 — жив, 0 — умер	после наблюдения	0 / 0	исключить: неизвестна в момент применения модели, отражает исход лечения
GTVn_n_nodes	число поражённых лимфоузлов, выделенных на маске GTVn	целый, 0–16	до начала лечения, по диагностической КТ	0 / 0	оставить, 0 означает отсутствие узлов и объясняет пропуски признаков GTVn, заменяет 3 исключённых признака
Dose_per_fraction	вычисленная: доза на фракцию, Гр (доза / число фракций)	непрерывный, 1,8–2,4	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить, заменяет 1 исключённый признак
Target_local_recurrence	целевая: 1 — локальный рецидив, 0 — нет	бинарный: 0 (128), 1 (12)	после наблюдения не менее 2 лет	158 (53,0 %) / 0	целевая переменная
GTVp_shape_MeshVolume	объём по треугольной сетке (GTVp)	непрерывный, мм ³ , > 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 23 исключённых признака
GTVp_shape_Sphericity	сферичность (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_shape_Elongation	вытянутость: отношение второй главной оси к первой (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_shape_Flatness	уплощённость: отношение третьей главной оси к первой (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_firstorder_10Percentile	10-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVp_firstorder_90Percentile	90-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 2 исключённых признака
GTVp_firstorder_Entropy	энтропия гистограммы плотностей (GTVp)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 26 исключённых признаков
GTVp_firstorder_Kurtosis	экспесс распределения плотностей (GTVp)	непрерывный, ≥ 1	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 3 исключённых признака
GTVp_firstorder_Maximum	максимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_firstorder_Minimum	минимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 25 исключённых признаков
GTVp_glcm_Correlation	GLCM: корреляция уровней соседних вокселей (GTVp)	непрерывный, $[-1, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 4 исключённых признака
GTVp_glcm_InverseVariance	GLCM: обратная дисперсия (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_gldm_DependenceNonUniformityNormalized	GLDM: нормированная неоднородность зависимостей (GTVp)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 5 исключённых признаков
GTVp_glszm_SizeZoneNonUniformityNormalized	GLSZM: нормированная неоднородность размеров зон (GTVp)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак
GTVp_ngtdm_Busyness	NGTDM: «занятость» — частота смены тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак
GTVp_ngtdm_Contrast	NGTDM: контраст соседних тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVn_shape_MeshVolume	объём по треугольной сетке (GTVn)	непрерывный, мм ³ , > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 15 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_shape_Elongation	вытянутость: отношение второй главной оси к первой (GTVn)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 1 исключённый признак, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_shape_Maximum2DDiameterSlice	наибольший диаметр в аксиальной плоскости (GTVn)	непрерывный, мм, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVn_firstorder_10Percentile	10-й перцентиль плотности (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 0 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_90Percentile	90-й перцентиль плотности (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Entropy	энтропия гистограммы плотностей (GTVn)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 32 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Kurtosis	эксцесс распределения плотностей (GTVn)	непрерывный, ≥ 1	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 0 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Maximum	максимальная плотность (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Minimum	минимальная плотность (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 6 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Skewness	асимметрия распределения плотностей (GTVn)	непрерывный	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 0 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_ClusterShade	GLCM: асимметрия кластеров (GTVn)	непрерывный	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 0 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_Correlation	GLCM: корреляция уровней соседних вокселей (GTVn)	непрерывный, $[-1, 1]$	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_Idmn	GLCM: нормированный обратный момент разности (однородность) (GTVn)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVn_glcm_InverseVariance	GLCM: обратная дисперсия (GTVn)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 2 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_gldm_LargeDependenceHighGrayLevelEmphasis	GLDM: крупные зависимости высоких уровней (GTVn)	непрерывный, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 2 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glrlm_LowGrayLevelRunEmphasis	GLRLM: преобладание серий низких уровней (GTVn)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 6 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glrlm_RunEntropy	GLRLM: энтропия серий (GTVn)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 1 исключённый признак, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glszm_LargeAreaLowGrayLevelEmphasis	GLSZM: крупные зоны низких уровней (GTVn)	непрерывный, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 3 исключённых признака, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glszm_SizeZoneNonUniformityNormalized	GLSZM: нормированная неоднородность размеров зон (GTVn)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 1 исключённый признак, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_ngtdm_Strength	NGTDM: сила текстуры (GTVn)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить, заменяет 0 исключённых признаков, пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Таблица 1: Словарь переменных и решений первичного анализа.