# Материалы и методы

## Исход и момент применения модели

В наборе два возможных исхода: локальный рецидив первичной опухоли и жизненный статус на момент последнего наблюдения. Жизненный статус известен для всех 298 пациентов, но без времени наблюдения смерть в первый год и через несколько лет неразличимы, а общая выживаемость зависит и от причин, не связанных с облучённым очагом. Поэтому исходом выбран локальный рецидив, заданный авторами набора [1]: 1 — рецидив в той же или иной подобласти ротоглотки, 0 — его отсутствие. Этот исход используется в соревновании на Kaggle [2], которое принимает решения в режиме поздней отправки (Late Submission), что позволяет независимо проверить предсказания для тестовой части. По условиям соревнования модель строится по первичной опухоли, без признаков лимфоузлов.

Исход означает рецидив за всё время наблюдения. Времени до рецидива и длительности наблюдения в таблице нет, поэтому горизонт прогноза задать нельзя. По описанию набора всех пациентов наблюдали более двух лет [1], так что отсутствие рецидива означает его отсутствие как минимум за этот срок.

Исход известен для 140 пациентов обучающей части: 12 с рецидивом и 128 без него. 158 пациентов тестовой части без значения исхода в аналитическую таблицу не вошли и оставлены для проверки на Kaggle. Малое число событий требует жёсткого ограничения числа признаков при моделировании [3].

Модель применяется после стадирования и утверждения плана лечения, до его начала: тогда оценка риска позволяет обсуждать эскалацию дозы или более частое наблюдение. К этому моменту известны диагностическая компьютерная томография (КТ), демографические данные, курение, TNM и стадия, степень дифференцировки, назначенные доза и фракционирование и решение о химиотерапии. Поэтому признаками не могут быть фактическая длительность курса лучевой терапии (ЛТ), известная лишь после его окончания, и жизненный статус: это была бы утечка информации из будущего [4]. Доза и число фракций в описании набора приведены как полученные пациентом [1], а они известны только после курса. Поэтому принято допущение, что полученные значения совпадают с назначенными: все сочетания дозы и числа фракций соответствуют стандартным схемам (60–72 Гр за 30–40 фракций), а прерванный курс дал бы промежуточные значения. То же допущение принято для химиотерапии.

## Первичный анализ данных

Использована итоговая таблица этапа извлечения признаков: 298 пациентов, идентификатор, часть набора, 18 клинических переменных, число поражённых лимфоузлов и по 107 радиомических признаков макроскопического объёма первичной опухоли (gross tumor volume, GTVp) и лимфоузлов (GTVn); исходный файл не изменялся. Выведены все значения 14 категориальных переменных и наименьшее и наибольшее значения количественных, для клинических — в сравнении с допустимым диапазоном. Разных написаний одной категории нет. Пропуски записаны пустыми ячейками («не поддаётся оценке» [1]), в категории N и стадии есть служебный код X («не может быть оценена»).

Значение заменялось верным, только если оно однозначно восстанавливается по другим полям записи, а служебные коды и невосстановимые ошибки заменялись пропуском. Код X у одного пациента заменён пропуском в обеих переменных. У одного пациента при T4N1 указана стадия III, хотя по 7-му изданию классификации Американского объединённого комитета по раку (AJCC) T4 без отдалённых метастазов означает стадию IV [5], и стадия исправлена. У 7 курящих и бывших курильщиков указано 0 пачко-лет, что противоречит статусу, и значения заменены пропуском. Всего в клинических переменных изменено 10 значений: 2 в стадии, 1 в категории N и 7 в пачко-годах. Доза за фракцию (1,8–2,4 Гр) и число суток на фракцию (0,98–1,70, меньше единицы при облучении дважды в день) находятся в допустимом диапазоне.

Максимальная плотность в маске опухоли выше 3071 единицы Хаунсфилда (HU), верхней границы стандартной шкалы КТ, найдена у 2 пациентов, а у пациента 146 обучающей части достигает 12 356 HU. У тканей таких значений не бывает, их дают металлические предметы, например зубные пломбы. Металл искажает распределение плотности и текстуру, а значения для ткани не восстановить, поэтому у этих пациентов все 93 признака плотности и текстуры заменены пропуском, признаки формы сохранены. Минимальная плотность ниже $-1024$ HU (ниже воздуха) ещё у 8 пациентов вызвана выбросами интерполяции при передискретизации в отдельных вокселях, и у них пропуском заменены только минимум и размах. Пациенты 219, 257 и 289 с некорректными масками опухоли относятся к тестовой части и в аналитическую таблицу не входят. Для Kaggle нужно предсказание для каждого тестового пациента, поэтому они сохранены, а влияние ошибок разметки будет учтено при интерпретации.

Пропуски есть в степени дифференцировки (43),

пачко-годах (21: 14 исходных и 7 после исправления), расе, категории N и стадии (по 1), во всех признаках лимфоузлов у 45 пациентов без поражённых узлов, а после исправления — в минимуме и размахе плотности (по 10) и остальных признаках плотности и текстуры (по 2). В аналитической когорте их доля составляет 11,4 % в степени дифференцировки, 7,1 % в пачко-годах, 5,0 % в минимуме и размахе и 0,7 % (один пациент) в остальных признаках плотности и текстуры. Большая доля пропусков считалась доводом за исключение переменной, а не автоматическим критерием. Здесь доли невелики, а степень дифференцировки и курение клинически значимы, поэтому из-за пропусков ничего не исключено.

Исключены идентификатор (сохранён как ключ строки), исход, отметка части набора, длительность курса ЛТ, жизненный статус, все 108 признаков лимфоузлов (107 радиомических и число узлов) и дубликат: полная энергия (TotalEnergy) совпадает с энергией (Energy), так как при вокселе 1 мм$^3$ они отличаются лишь множителем [6]. Констант нет. Добавлена вычисленная доза за фракцию, поскольку при равной суммарной дозе эффект облучения зависит от фракционирования.

Избыточность 111 количественных признаков (5 клинических и 106 признаков опухоли) сокращалась последовательным отбором: признак оставлялся, если модуль коэффициента корреляции с каждым ранее оставленным не превышал 0,7, иначе исключался и засчитывался наиболее связанному с ним оставленному. Порядок предпочтения не зависит от исхода: клинические признаки как доступные в рутинной практике, затем объём опухоли (установленный прогностический фактор) и сферичность, далее остальные признаки в порядке PyRadiomics. Использовалась ранговая корреляция Спирмена, так как у 69 % радиомических признаков модуль коэффициента асимметрии больше 1. Порог 0,7 (почти половина общей ранговой дисперсии) выбран жёстким из-за малого числа событий. Корреляции считались по всем 298 пациентам без использования исхода. Оставлено 20 признаков (4 клинических и 16 радиомических), исключён 91, наибольший модуль корреляции среди оставленных равен 0,674. Больше всего признаков заменяют энтропия (27), минимальная плотность (24) и объём опухоли (23).

Аналитическая таблица содержит 140 пациентов, код пациента, исход и 31 признак: 11 категориальных и 20 количественных. Пропуски (16 в степени дифференцировки, 10 в пачко-годах, 7 в минимальной плотности и по одному в остальных 11 признаках плотности и текстуры) на этом этапе не заполнялись, а связь признаков с исходом не изучалась. Заполнение и отбор по исходу будут выполняться внутри перекрёстной проверки, чтобы оценка качества не была оптимистично смещена.

## Ссылки


[1] Hesham Elhalawani, Abdallah S. R. Mohamed, Aubrey L. White и др. «Matched computed tomography segmentation and demographic data for oropharyngeal cancer radiomics challenges». В: *Scientific Data* 4 (2017), с. 170077. DOI: 10.1038/sdata.2017.77.

[2] Amber Simpson и др. *Oropharynx Cancer (OPC) Radiomics Challenge :: Local Recurrence Prediction*. https://www.kaggle.com/competitions/opc-recurrence. Kaggle. 2016.

[3] Richard D. Riley, Joie Ensor, Kym I. E. Snell и др. «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368 (2020), с. m441. DOI: 10.1136/bmj.m441.

[4] Shachar Kaufman и др. «Leakage in data mining: formulation, detection, and avoidance». В: *ACM Transactions on Knowledge Discovery from Data* 6.4 (2012), с. 15. DOI: 10.1145/2382577.2382579.

[5] Stephen B. Edge и Carolyn C. Compton. «The American Joint Committee on Cancer: the 7th edition of the AJCC cancer staging manual and the future of TNM». В: *Annals of Surgical Oncology* 17.6 (2010), с. 1471–1474. DOI: 10.1245/s10434-010-0985-4.

[6] PyRadiomics community. *PyRadiomics documentation: radiomic features and customization of extraction*. 2025. URL: https://pyradiomics.readthedocs.io.

## Словарь переменных и решений

Приведены все клинические и служебные переменные исходной таблицы, вычисленная доза за фракцию, исход и оставленные радиомические признаки первичной опухоли (16 из 107) с числом исключённых признаков, которые каждый из них заменяет. Признаки лимфоузлов исключены целиком: число узлов приведено как переменная исходной таблицы с решением об исключении, а 107 радиомических признаков лимфоузлов в словаре не приводятся. Пропуски указаны после исправления значений во всей таблице (298 пациентов) и в аналитической когорте (140 пациентов). Момент доступности дан относительно применения модели после утверждения плана лечения.

| Переменная | Смысл | Тип, допустимые значения | Момент доступности | Пропуски (298 / 140) | Решение и комментарий |
|---|---|---|---|---|---|
| `Patient_ID` | код пациента, присвоенный при анонимизации, совпадает с именем папки снимков | целый, 1–315, уникален | служебная, всегда | 0 / 0 | оставить как ключ строки, не признак: идентификатор не несёт клинической информации |
| `Fold` | часть набора соревнования | категориальный: Training, Test | служебная, задана организаторами | 0 / 0 | исключить: служебная переменная |
| `Local_tumor_recurrence` | локальный рецидив первичной опухоли за период наблюдения | бинарный: 0, 1 | после наблюдения не менее 2 лет | 158 (53,0 %) / 0 | исключить из признаков: источник целевой переменной |
| `Gender` | пол | категориальный: Male, Female | до начала лечения, при постановке диагноза | 0 / 0 | оставить |
| `Age_at_diagnosis` | возраст на момент диагноза, лет | целый, 30–89 | до начала лечения, при постановке диагноза | 0 / 0 | оставить, заменяет 0 исключённых признаков |
| `Race` | раса | категориальный: White, Black, Hispanic, Asian, American_Indian/ Alaska_Native | до начала лечения, при постановке диагноза | 1 (0,3 %) / 0 | оставить, пустая ячейка — пропуск, не заполнять |
| `Tumor_side` | латеральность опухоли | категориальный: L, R, Bilateral | до начала лечения, после стадирования | 0 / 0 | оставить |
| `Tumor_subsite` | подобласть ротоглотки | категориальный: BOT, Tonsil, GPS, Soft_palate, Pharyngeal_wall, Other | до начала лечения, после стадирования | 0 / 0 | оставить |
| `T_category` | категория T (AJCC 7) | порядковый: 1–4 | до начала лечения, после стадирования | 0 / 0 | оставить |
| `N_category` | категория N (AJCC 7) | порядковый: 0, 1, 2a, 2b, 2c, 3 | до начала лечения, после стадирования | 1 (0,3 %) / 0 | оставить, служебный код X (1 значение) заменён пропуском |
| `AJCC_Stage` | стадия по AJCC 7, определяется T и N при M0 | порядковый: I–IV | до начала лечения, после стадирования | 1 (0,3 %) / 0 | оставить, X (1) заменён пропуском, III при T4N1 (1) исправлено на IV |
| `Pathological_grade` | степень дифференцировки опухоли | порядковый: I, I-II, II, II-III, III, IV | до начала лечения, по биопсии | 43 (14,4 %) / 16 (11,4 %) | оставить: клинически значимый фактор, пропуски на этом этапе не заполнять |
| `Smoking_status_at_diagnosis` | статус курения на момент диагноза | категориальный: Never, Former, Current | до начала лечения, при постановке диагноза | 0 / 0 | оставить |

*Продолжение на следующей странице*

| Переменная | Смысл | Тип, допустимые значения | Момент доступности | Пропуски (298 / 140) | Решение и комментарий |
|---|---|---|---|---|---|
| `Smoking_Pack-Years` | кумулятивное курение, пачко-лет | непрерывный, $\geq 0$, 0 только при Never | до начала лечения, при постановке диагноза | 21 (7,0 %) / 10 (7,1 %) | оставить, 7 нулей при Current/Former заменены пропуском, заменяет 0 исключённых признаков |
| `Radiation_treatment_course_duration` | фактическая длительность курса ЛТ, дни | целый, 32–56 | после окончания ЛТ | 0 / 0 | исключить: неизвестна в момент применения модели |
| `Total_prescribed_Radiation_treatment_dose` | суммарная доза, Гр (в описании набора — полученная) | целый: 60, 63, 66, 70, 72 | до начала ЛТ как назначенное значение (допущение: получено как назначено) | 0 / 0 | оставить: все значения — стандартные назначенные дозы, поэтому полученная доза принята равной назначенной, заменяет 0 исключённых признаков |
| `#_Radiation_treatment_fractions` | число фракций (в описании набора — полученное) | целый, 30–40 | до начала ЛТ как назначенное значение (допущение: получено как назначено) | 0 / 0 | исключить: избыточна, $\lvert\rho\rvert > 0{,}7$ с Dose_per_fraction |
| `Induction_Chemotherapy` | индукционная химиотерапия до ЛТ | бинарный: Y, N | до начала ЛТ как назначенное значение (допущение: получено как назначено) | 0 / 0 | оставить: принято, что проведена как запланирована |
| `Concurrent_chemotherapy` | химиотерапия одновременно с ЛТ | бинарный: Y, N | до начала ЛТ как назначенное значение (допущение: получено как назначено) | 0 / 0 | оставить: принято, что проведена как запланирована |
| `KM_Overall_survival_censor` | жизненный статус на последнем наблюдении | бинарный: 1 — жив, 0 — умер | после наблюдения | 0 / 0 | исключить: альтернативный исход, известен в обеих частях набора, но без времени наблюдения, неизвестен в момент применения модели |
| `GTVn_n_nodes` | число поражённых лимфоузлов, выделенных на маске GTVn | целый, 0–16 | до начала лечения, по диагностической КТ | 0 / 0 | исключить вместе со всеми признаками GTVn: по условиям соревнования модель строится по первичной опухоли |
| `Dose_per_fraction` | вычисленная: доза за фракцию, Гр (доза / число фракций) | непрерывный, 1,8–2,4 | до начала ЛТ как назначенное значение (допущение: получено как назначено) | 0 / 0 | оставить, заменяет 1 исключённый признак |
| `Target_local_recurrence` | целевая: 1 — локальный рецидив, 0 — нет | бинарный: 0 (128), 1 (12) | после наблюдения не менее 2 лет | 158 (53,0 %) / 0 | целевая переменная |

*Продолжение на следующей странице*

| Переменная | Смысл | Тип, допустимые значения | Момент доступности | Пропуски (298 / 140) | Решение и комментарий |
|---|---|---|---|---|---|
| `GTVp_shape_MeshVolume` | объём по треугольной сетке (GTVp) | непрерывный, мм$^3$, $> 0$ | до начала лечения, по диагностической КТ | 0 / 0 | оставить, заменяет 23 исключённых признака |
| `GTVp_shape_Sphericity` | сферичность (GTVp) | непрерывный, $(0, 1]$ | до начала лечения, по диагностической КТ | 0 / 0 | оставить, заменяет 0 исключённых признаков |
| `GTVp_shape_Elongation` | вытянутость: отношение второй главной оси к первой (GTVp) | непрерывный, $(0, 1]$ | до начала лечения, по диагностической КТ | 0 / 0 | оставить, заменяет 0 исключённых признаков |
| `GTVp_shape_Flatness` | уплощённость: отношение третьей главной оси к первой (GTVp) | непрерывный, $(0, 1]$ | до начала лечения, по диагностической КТ | 0 / 0 | оставить, заменяет 0 исключённых признаков |
| `GTVp_firstorder_10Percentile` | 10-й перцентиль плотности (GTVp) | непрерывный, HU | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 1 исключённый признак, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_firstorder_90Percentile` | 90-й перцентиль плотности (GTVp) | непрерывный, HU | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 2 исключённых признака, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_firstorder_Entropy` | энтропия гистограммы плотностей (GTVp) | непрерывный, бит, $\geq 0$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 27 исключённых признаков, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_firstorder_Kurtosis` | эксцесс распределения плотностей (GTVp) | непрерывный, $\geq 1$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 3 исключённых признака, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_firstorder_Maximum` | максимальная плотность (GTVp) | непрерывный, HU, от $-1024$ до 3071 | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 0 исключённых признаков, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_firstorder_Minimum` | минимальная плотность (GTVp) | непрерывный, HU, от $-1024$ до 3071 | до начала лечения, по диагностической КТ | 10 (3,4 %) / 7 (5,0 %) | оставить, заменяет 24 исключённых признака, у 2 пациентов с металлом в маске значение заменено пропуском, ещё 8 значений ниже $-1024$ HU заменены пропуском |
| `GTVp_glcm_Correlation` | GLCM: корреляция уровней соседних вокселей (GTVp) | непрерывный, $[-1, 1]$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 4 исключённых признака, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_glcm_InverseVariance` | GLCM: обратная дисперсия (GTVp) | непрерывный, $\geq 0$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 0 исключённых признаков, у 2 пациентов с металлом в маске значение заменено пропуском |

*Продолжение на следующей странице*

| Переменная | Смысл | Тип, допустимые значения | Момент доступности | Пропуски (298 / 140) | Решение и комментарий |
|---|---|---|---|---|---|
| `GTVp_gldm_DependenceNon UniformityNormalized` | GLDM: нормированная неоднородность зависимостей (GTVp) | непрерывный, (0, 1] | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 5 исключённых признаков, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_glszm_SizeZoneNon UniformityNormalized` | GLSZM: нормированная неоднородность размеров зон (GTVp) | непрерывный, (0, 1] | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 1 исключённый признак, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_ngtdm_Busyness` | NGTDM: «занятость» — частота смены тонов (GTVp) | непрерывный, $\geq 0$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 1 исключённый признак, у 2 пациентов с металлом в маске значение заменено пропуском |
| `GTVp_ngtdm_Contrast` | NGTDM: контраст соседних тонов (GTVp) | непрерывный, $\geq 0$ | до начала лечения, по диагностической КТ | 2 (0,7 %) / 1 (0,7 %) | оставить, заменяет 0 исключённых признаков, у 2 пациентов с металлом в маске значение заменено пропуском |

Таблица 1: Словарь переменных и решений первичного анализа.