

Материалы и методы

Исход и момент применения модели

Модель предсказывает локальный рецидив первичной опухоли после радикальной лучевой терапии (ЛТ). Целевая переменная `Target_local_recurrence` равна 1, если за период наблюдения зарегистрирован рецидив в той же или иной подобласти ротоглотки, и 0, если рецидива не было. Значение перенесено без изменений из `Local_tumor_recurrence`, заполненной авторами набора по данным наблюдения (Elhalawani и др. 2017). Эта конечная точка выбрана потому, что локальный контроль – прямая цель облучения первичного очага.

В таблицах нет дат, длительности наблюдения и времени до рецидива, поэтому исход нельзя пересчитать на иной горизонт и он используется в форме, заданной организаторами. Горизонт задан критерием включения – наблюдением более двух лет (Elhalawani и др. 2017), покрывающим период, на который приходится основная часть локальных неудач после ЛТ. По критериям отбора все 128 пациентов без события наблюдались не меньше горизонта, однако индивидуально проверить это по таблице нельзя.

В анализ вошли 140 пациентов обучающей части: 12 с рецидивом и 128 без него. Малое число событий – главное ограничение данных, требующее жёсткого ограничения числа признаков при моделировании (Riley и др. 2020).

Модель применяется после стадирования и утверждения плана лечения, до начала любой его части. К этому моменту известны диагностическая КТ, по которой построены маски `GTVp` и `GTVn`, демографические данные, анамнез курения, TNM и стадия, степень дифференцировки по биопсии, предписанные доза и фракционирование и решение о химиотерапии. Оценка риска при выбранном режиме позволяет обсуждать эскалацию дозы или более плотное наблюдение после ЛТ; раньше параметры лечения неизвестны, позже прогноз теряет практическую ценность. Поэтому как признаки нельзя использовать фактическую длительность курса `Radiation_treatment_course_duration`, зависящую от перерывов и известную лишь после окончания ЛТ, и жизненный статус `KM_Overall_survival_sensor`, относящийся к периоду после лечения: это была бы утечка информации из будущего (Kaufman и др. 2012).

Первичный анализ данных

Использована итоговая таблица этапа извлечения признаков (298 пациентов, 235 столбцов: 20 клинических и

служебных, число узлов `GTVn_n_nodes` и по 107 признаков `GTVp` и `GTVn`); исходный файл не изменялся. Для 14 категориальных переменных выведены все значения, для количественных – наименьшее и наибольшее, для клинических – в сравнении с допустимым диапазоном. Разных написаний одной категории и значений вне диапазонов нет, пропуски записаны пустыми ячейками, а в `N_category` и `AJCC_Stage` встречается служебный код X («не может быть оценена»).

Значение заменялось верным, только если оно однозначно восстанавливается по другим полям записи; служебные коды и невозстановимые противоречия заменялись пропуском. Код X у одного пациента заменён пропуском в обеих переменных. У одного пациента при T4N1 указана стадия III, хотя по 7-му изданию AJCC при M0 категория T4 означает стадию IV (Edge и др. 2010); стадия выводится из T и N однозначно и исправлена. У 7 пациентов со статусом Current или Former указано 0 пачко-лет, что противоречит статусу, экспозицию восстановить нельзя, значения заменены пропуском. Всего изменено 10 значений: 2 в `AJCC_Stage`, 1 в `N_category` и 7 в `Smoking_Pack-Years`.

Доза на фракцию (1,8–2,4 Гр) и число суток на фракцию (0,98–1,70, меньше единицы при облучении дважды в день) правдоподобны. Плотность ниже –1024 HU у 12 пациентов и выше 3071 HU у 5 объясняется выбросами B-сплайн-интерполяции и артефактами от металла, это свойства вычисленных признаков, а не ошибки записи, и они сохранены. Маска `GTVn` есть у 2 пациентов с N0 и отсутствует у 19 с N1–N3; это не исправлялось, так как маски строились по видимым на КТ узлам и отсутствуют после эксцизионной биопсии узла (Elhalawani и др. 2017).

Пропуски есть в `Pathological_grade` (43), `Smoking_Pack-Years` (21, из них 7 после исправления), `Race`, `N_category` и `AJCC_Stage` (по 1), а также во всех 107 признаках `GTVn` у 45 пациентов, в `GTVp` пропусков нет. Пропуски `GTVn` приходятся ровно на пациентов с `GTVn_n_nodes` = 0, т. е. означают отсутствие узлов, а не потерю данных. В тренировочной выборке доля пропусков составляет 11,4 % в степени дифференцировки, 7,1 % в пачко-годах и 14,3 % в `GTVn`. Переменная исключалась при доле пропусков выше 30 %, так как иначе её значения определялись бы в основном моделью заполнения – таких переменных нет.

Исключены идентификатор (сохранён как ключ), источник целевой переменной, служебная `Fold`, две недоступные в момент применения переменные и 2 дубликата: `firstorder_TotalEnergy` в обеих масках совпадает с `firstorder_Energy`, поскольку при вокселе

1 мм³ они отличаются лишь множителем (PyRadiomics community 2025). Констант нет. Добавлена вычисленная `Dose_per_fraction`, так как при равной суммарной дозе эффект облучения зависит от фракционирования.

Избыточность 218 количественных признаков сокращалась последовательным отбором: признак оставлялся, если модуль корреляции с каждым ранее оставленным не превышал 0,7, иначе исключался и засчитывался наиболее связанному оставленному. Порядок предпочтения не зависит от исхода: клинические признаки как доступные в рутинной практике, затем GTVp как область конечной точки, затем число узлов и GTVn, внутри маски первыми идут объём (установленный прогностический фактор) и сферичность, далее порядок PyRadiomics. Использовалась ранговая корреляция Спирмена, так как распределения признаков сильно скошены и содержат выбросы плотности. По-

рог 0,7 (более половины общей ранговой дисперсии) выбран жёстким из-за малого числа событий. Корреляции считались по всем 298 пациентам без использования исхода, для GTVn – по 253 пациентам с узлами. Оставлен 41 признак (4 клинических, `GTVn_n_nodes`, 16 GTVp и 20 GTVn), исключено 177, наибольший модуль корреляции среди оставленных – 0,698. Больше всего признаков заменяют энтропия GTVn (32) и GTVp (26), минимальная плотность GTVp (25) и объём GTVp (23).

Аналитическая таблица содержит 140 пациентов, код пациента, целевую переменную и 52 признака: 11 категориальных и 41 количественный. Пропуски (16 в степени дифференцировки, 10 в пачко-годах, по 20 в признаках GTVn) на этом этапе не заполнялись, а связь признаков с исходом не изучалась, чтобы заполнение и отбор по исходу выполнять внутри кросс-валидации без оптимистичного смещения оценки.

Ссылки

Edge, Stephen B. и Carolyn C. Compton (2010). «The American Joint Committee on Cancer: the 7th edition of the AJCC cancer staging manual and the future of TNM». В: *Annals of Surgical Oncology* 17.6, с. 1471—1474. DOI: 10.1245/s10434-010-0985-4.

Elhalawani, Hesham, Abdallah S. R. Mohamed, Aubrey L. White и др. (2017). «Matched computed tomography segmentation and demographic data for oropharyngeal cancer radiomics challenges». В: *Scientific Data* 4, с. 170077. DOI: 10.1038/sdata.2017.77.

Kaufman, Shachar и др. (2012). «Leakage in data mining: formulation, detection, and avoidance». В: *ACM Transactions on Knowledge Discovery from Data* 6.4, с. 15. DOI: 10.1145/2382577.2382579.

PyRadiomics community (2025). *PyRadiomics documentation: radiomic features and customization of extraction*. URL: <https://pyradiomics.readthedocs.io>.

Riley, Richard D., Joie Ensor, Kym I. E. Snell и др. (2020). «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368, с. m441. DOI: 10.1136/bmj.m441.

Словарь переменных и решений

Приведены все клинические и служебные переменные исходной таблицы, число узлов GTVn_n_nodes, вычисленная Dose_per_fraction, целевая переменная и оставленные радиомические признаки (16 из 107 для GTVp и 20 из 107 для GTVn) с числом исключённых признаков, которые каждый из них заменяет. Пропуски указаны после исправления значений во всей таблице (298 пациентов) и в аналитической когорте (140 пациентов), момент доступности – относительно применения модели после утверждения плана лечения.

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Patient_ID	код пациента, присвоенный при анонимизации; совпадает с именем папки снимков	целый, 1–315, уникален	служебная, всегда	0 / 0	оставить как ключ строки; не признак: идентификатор не несёт клинической информации
Fold	часть набора соревнования	категориальный: Training, Test	служебная, задана организаторами	0 / 0	исключить: служебная переменная
Local_tumor_recurrence	локальный рецидив первичной опухоли за период наблюдения	бинарный: 0, 1	после наблюдения не менее 2 лет	158 (53,0 %) / 0	исключить из признаков: источник целевой переменной
Gender	пол	категориальный: Male, Female	до начала лечения, при постановке диагноза	0 / 0	оставить
Age_at_diagnosis	возраст на момент диагноза, лет	целый, 30–89	до начала лечения, при постановке диагноза	0 / 0	оставить; заменяет 0 исключённых признаков
Race	раса	категориальный: White, Black, Hispanic, Asian, American_Indian/Alaska_Native	до начала лечения, при постановке диагноза	1 (0,3 %) / 0	оставить; пустая ячейка — пропуск, не заполнять
Tumor_side	латеральность опухоли	категориальный: L, R, Bilateral	до начала лечения, после стадирования	0 / 0	оставить
Tumor_subsite	подобласть ротоглотки	категориальный: BOT, Tonsil, GPS, Soft_palate, Pharyngeal_wall, Other	до начала лечения, после стадирования	0 / 0	оставить
T_category	категория T (AJCC 7)	порядковый: 1–4	до начала лечения, после стадирования	0 / 0	оставить
N_category	категория N (AJCC 7)	порядковый: 0, 1, 2a, 2b, 2c, 3	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить; служебный код X (1 значение) заменён пропуском
AJCC_Stage	стадия по AJCC 7, определяется T и N при M0	порядковый: I–IV	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить; X (1) заменён пропуском, III при T4N1 (1) исправлено на IV
Pathological_grade	степень дифференцировки опухоли	порядковый: I, I-II, II, II-III, III, IV	до начала лечения, по биопсии	43 (14,4 %) / 16 (11,4 %)	оставить; пропуски не заполнять, доля ниже порога 30 %
Smoking_status_at_diagnosis	статус курения на момент диагноза	категориальный: Never, Former, Current	до начала лечения, при постановке диагноза	0 / 0	оставить

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Smoking_Pack-Years	кумулятивное курение, пачко-лет	непрерывный, ≥ 0 ; 0 только при Never	до начала лечения, при постановке диагноза	21 (7,0 %) / 10 (7,1 %)	оставить; 7 нулей при Current/Former заменены пропуском; заменяет 0 исключённых признаков
Radiation_treatment_course_duration	фактическая длительность курса ЛТ, дни	целый, 32–56	после окончания ЛТ	0 / 0	исключить: неизвестна в момент применения модели
Total_prescribed_Radiation_treatment_dose	суммарная предписанная доза, Гр	целый: 60, 63, 66, 70, 72	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить; заменяет 0 исключённых признаков
#_Radiation_treatment_fractions	число фракций	целый, 30–40	до начала ЛТ, при утверждении плана лечения	0 / 0	исключить: избыточна, $ \rho > 0,7$ с Dose_per_fraction
Induction_Chemotherapy	индукционная химиотерапия до ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
Concurrent_chemotherapy	химиотерапия одновременно с ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
KM_Overall_survival_censor	жизненный статус на последнем наблюдении	бинарный: 1 — жив, 0 — умер	после наблюдения	0 / 0	исключить: неизвестна в момент применения модели, отражает исход лечения
GTVn_n_nodes	число поражённых лимфоузлов, выделенных на маске GTVn	целый, 0–16	до начала лечения, по диагностической КТ	0 / 0	оставить; 0 означает отсутствие узлов и объясняет пропуски признаков GTVn; заменяет 3 исключённых признака
Dose_per_fraction	вычисленная: доза на фракцию, Гр (доза / число фракций)	непрерывный, 1,8–2,4	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить; заменяет 1 исключённый признак
Target_local_recurrence	целевая: 1 — локальный рецидив, 0 — нет	бинарный: 0 (128), 1 (12)	после наблюдения не менее 2 лет	158 (53,0 %) / 0	целевая переменная
GTVp_shape_MeshVolume	объём по треугольной сетке (GTVp)	непрерывный, мм ³ , > 0	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 23 исключённых признака
GTVp_shape_Sphericity	сферичность (GTVp)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVp_shape_Elongation	вытянутость: отношение второй главной оси к первой (GTVp)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVp_shape_Flatness	уплощённость: отношение третьей главной оси к первой (GTVp)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVp_firstorder_10Percentile	10-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 1 исключённый признак

Продолжение на следующей странице

ст

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVp_firstorder_90Percentile	90-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 2 исключённых признака
GTVp_firstorder_Entropy	энтропия гистограммы плотностей (GTVp)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 26 исключённых признаков
GTVp_firstorder_Kurtosis	экспесс распределения плотностей (GTVp)	непрерывный, ≥ 1	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 3 исключённых признака
GTVp_firstorder_Maximum	максимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVp_firstorder_Minimum	минимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 25 исключённых признаков
GTVp_glcm_Correlation	GLCM: корреляция уровней соседних вокселей (GTVp)	непрерывный, $[-1; 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 4 исключённых признака
GTVp_glcm_InverseVariance	GLCM: обратная дисперсия (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVp_gldm_DependenceNonUniformityNormalized	GLDM: нормированная неоднородность зависимостей (GTVp)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 5 исключённых признаков
GTVp_glszm_SizeZoneNonUniformityNormalized	GLSZM: нормированная неоднородность размеров зон (GTVp)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 1 исключённый признак
GTVp_ngtdm_Busyness	NGTDM: «занятость» — частота смены тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 1 исключённый признак
GTVp_ngtdm_Contrast	NGTDM: контраст соседних тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить; заменяет 0 исключённых признаков
GTVn_shape_MeshVolume	объём по треугольной сетке (GTVn)	непрерывный, мм ³ , > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 15 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_shape_Elongation	вытянутость: отношение второй главной оси к первой (GTVn)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 1 исключённый признак; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_shape_Maximum2DDiameterSlice	наибольший диаметр в аксиальной плоскости (GTVn)	непрерывный, мм, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVn_firstorder_10Percentile	10-й перцентиль плотности (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 0 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_90Percentile	90-й перцентиль плотности (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Entropy	энтропия гистограммы плотностей (GTVn)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 32 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Kurtosis	эксцесс распределения плотностей (GTVn)	непрерывный, ≥ 1	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 0 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Maximum	максимальная плотность (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Minimum	минимальная плотность (GTVn)	непрерывный, HU	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 6 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_firstorder_Skewness	асимметрия распределения плотностей (GTVn)	непрерывный	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 0 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_ClusterShade	GLCM: асимметрия кластеров (GTVn)	непрерывный	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 0 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_Correlation	GLCM: корреляция уровней соседних вокселей (GTVn)	непрерывный, $[-1; 1]$	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glcm_Idmn	GLCM: нормированный обратный момент разности (однородность) (GTVn)	непрерывный, $(0; 1]$	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVn_glcm_InverseVariance	GLCM: обратная дисперсия (GTVn)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 2 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_gldm_LargeDependenceHighGrayLevelEmphasis	GLDM: крупные зависимости высоких уровней (GTVn)	непрерывный, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 2 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glrlm_LowGrayLevelRunEmphasis	GLRLM: преобладание серий низких уровней (GTVn)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 6 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glrlm_RunEntropy	GLRLM: энтропия серий (GTVn)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 1 исключённый признак; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glszm_LargeAreaLowGrayLevelEmphasis	GLSZM: крупные зоны низких уровней (GTVn)	непрерывный, > 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 3 исключённых признака; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_glszm_SizeZoneNonUniformityNormalized	GLSZM: нормированная неоднородность размеров зон (GTVn)	непрерывный, (0; 1]	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 1 исключённый признак; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять
GTVn_ngtdm_Strength	NGTDM: сила текстуры (GTVn)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	45 (15,1 %) / 20 (14,3 %)	оставить; заменяет 0 исключённых признаков; пропуск — нет узлов (GTVn_n_nodes = 0), не заполнять

Таблица 1: Словарь переменных и решений первичного анализа.