

Материалы и методы

Исход и момент применения модели

В наборе два возможных исхода: локальный рецидив первичной опухоли и жизненный статус на момент последнего наблюдения. Жизненный статус известен для всех 298 пациентов, однако времени наблюдения в таблице нет. Поэтому смерть в первый год и через несколько лет неразличимы, а для живых пациентов неизвестно, как долго они наблюдались. Кроме того, общая выживаемость зависит от отдалённых метастазов и сопутствующих заболеваний, не связанных с облучённым очагом. Исходом выбран локальный рецидив (1 — рецидив в той же или иной подобласти ротоглотки за период наблюдения, 0 — его отсутствие), заданный авторами набора [1]. Он прямо связан с первичной опухолью, на которую направлено облучение, и используется в соревновании на Kaggle [2], которое принимает решения в режиме поздней отправки (Late Submission). Это позволяет независимо проверить предсказания для тестовой части. По условиям соревнования модель строится по первичной опухоли, и признаки лимфоузлов в неё не включаются.

Времени до события в таблице нет, поэтому горизонт прогноза задан критерием включения в когорту — наблюдением более двух лет после лечения [1]. Этот срок покрывает период, на который приходится основная часть локальных неудач после лучевой терапии (ЛТ). По критериям отбора все 128 пациентов без рецидива наблюдались не меньше горизонта, однако индивидуально проверить это по таблице нельзя.

Исход известен для 140 пациентов обучающей части: 12 с рецидивом и 128 без него. 158 пациентов тестовой части без значения исхода в аналитическую таблицу не вошли и оставлены для проверки на Kaggle. Малое число событий — главное ограничение данных, требующее жёсткого ограничения числа признаков при моделировании [3].

Модель применяется после стадирования и утверждения плана лечения, до начала любой его части. К этому моменту известны диагностическая компьютерная томография (КТ), по которой построена маска опухоли, демографические данные, анамнез курения, категории TNM и стадия, степень дифференцировки по биопсии, предписанные доза и фракционирование, а также решение о химиотерапии. Оценка риска при выбранном режиме позволяет обсуждать эскалацию дозы или более частое наблюдение после ЛТ. Раньше параметры лечения неизвестны, а позже прогноз теряет практи-

ческую ценность. Поэтому признаками не могут быть фактическая длительность курса ЛТ, которая зависит от перерывов и известна лишь после его окончания, и жизненный статус, относящийся к периоду после лечения. Их включение означало бы утечку информации из будущего [4].

Первичный анализ данных

Использована итоговая таблица этапа извлечения признаков: 298 пациентов, идентификатор, часть набора, 18 клинических переменных, число поражённых лимфоузлов и по 107 радиомических признаков макроскопического объёма первичной опухоли (gross tumor volume, GTVp) и лимфоузлов (GTVn). Исходный файл не изменялся. Для 14 категориальных переменных выведены все значения, для количественных — наименьшее и наибольшее, для клинических — в сравнении с допустимым диапазоном. Разных написаний одной категории и значений вне диапазонов нет. Пропуски записаны пустыми ячейками (в описании набора — «не поддаётся оценке» [1]), а в категории N и стадии встречается служебный код X («не может быть оценена»).

Значение заменялось верным, только если оно однозначно восстанавливается по другим полям записи. Служебные коды и невозстановимые противоречия заменялись пропуском. Код X у одного пациента заменён пропуском в обеих переменных. У одного пациента при T4N1 указана стадия III, хотя по 7-му изданию классификации Американского объединённого комитета по раку (AJCC) при отсутствии отдалённых метастазов категория T4 означает стадию IV [5]. Стадия однозначно выводится из T и N, поэтому она исправлена. У 7 курящих и бывших курильщиков указано 0 пачко-лет, что противоречит статусу курения. Истинную экспозицию восстановить нельзя, поэтому значения заменены пропуском. Всего изменено 10 значений: 2 в стадии, 1 в категории N и 7 в пачко-годах.

Доза за фракцию (1,8–2,4 Гр) и число суток на фракцию (0,98–1,70) правдоподобны: значения меньше единицы соответствуют облучению дважды в день. Плотность в маске опухоли ниже —1024 единиц Хаунсфилда (HU) у 9 пациентов и выше 3071 HU у 2 пациентов объясняется выбросами интерполяции при передискретизации изображения и артефактами от стоматологических конструкций, не закрывавших опухоль [1]. Это свойства вычисленных признаков, а не ошибки записи, поэтому они сохранены. Маска лимфоузлов отсутствует у 19 пациентов с N1–N3, поскольку авторы не размечали узлы, если КТ выполнена после эксцизионной биопсии узла [1]. У 2 пациентов с N0 маска есть,

что противоречит тому же правилу. Для модели это несущественно, так как признаки лимфоузлов в неё не входят.

При извлечении признаков у пациентов 219, 257 и 289 выявлены некорректные маски первичной опухоли. Все трое относятся к тестовой части и в аналитическую таблицу не входят. Для проверки на Kaggle предсказание требуется для каждого пациента тестовой части, поэтому они сохранены в исходной таблице без исправления масок, а возможное влияние ошибок разметки будет учтено при интерпретации результата.

Пропуски есть в степени дифференцировки (43), пачко-годах (21: 14 исходных и 7 после исправления), расе, категории N и стадии (по 1), а также во всех признаках лимфоузлов у 45 пациентов без поражённых узлов. В признаках первичной опухоли пропусков нет. В аналитической когорте доля пропусков составляет 11,4 % в степени дифференцировки и 7,1 % в пачко-годах. Переменная исключалась при доле пропусков выше 30 %, так как иначе её значения определялись бы в основном моделью заполнения. Таких переменных нет.

Исключены идентификатор (сохранён как ключ строки), исход, служебная отметка части набора, длительность курса ЛТ, жизненный статус и все 108 признаков лимфоузлов (107 радиомических и число узлов). Исключён и дубликат: полная энергия (TotalEnergy) совпадает с энергией (Energy), так как при вокселе 1 мм³ они отличаются лишь множителем [6]. Констант нет. Добавлена вычисленная доза за фракцию, поскольку при равной суммарной дозе эффект облучения зави-

сит от фракционирования.

Избыточность 111 количественных признаков (5 клинических и 106 признаков опухоли) сокращалась последовательным отбором. Признак оставлялся, если модуль коэффициента корреляции с каждым ранее оставленным не превышал 0,7, иначе исключался и засчитывался наиболее связанному с ним оставленному признаку. Порядок предпочтения не зависит от исхода: сначала клинические признаки как доступные в рутинной практике, затем объём опухоли (установленный прогностический фактор) и сферичность, далее остальные признаки в порядке PyRadiomics. Использовалась ранговая корреляция Спирмена, так как у 78 % радиомических признаков модуль коэффициента асимметрии больше 1, а плотность содержит выбросы. Порог 0,7 (почти половина общей ранговой дисперсии) выбран жёстким из-за малого числа событий. Корреляции считались по всем 298 пациентам без использования исхода. Оставлено 20 признаков (4 клинических и 16 радиомических), исключён 91, наибольший модуль корреляции среди оставленных равен 0,674. Больше всего признаков заменяют энтропия (26), минимальная плотность (25) и объём опухоли (23).

Аналитическая таблица содержит 140 пациентов, код пациента, исход и 31 признак: 11 категориальных и 20 количественных. Пропуски (16 в степени дифференцировки и 10 в пачко-годах) на этом этапе не заполнялись, а связь признаков с исходом не изучалась. Заполнение и отбор по исходу будут выполняться внутри перекрёстной проверки, чтобы оценка качества не была оптимистично смещена.

Ссылки

- [1] Hesham Elhalawani, Abdallah S. R. Mohamed, Aubrey L. White и др. «Matched computed tomography segmentation and demographic data for oropharyngeal cancer radiomics challenges». В: *Scientific Data* 4 (2017), с. 170077. DOI: 10.1038/sdata.2017.77.
- [2] Amber Simpson и др. *Oropharynx Cancer (OPC) Radiomics Challenge :: Local Recurrence Prediction*. <https://www.kaggle.com/competitions/opc-recurrence>. Kaggle. 2016.
- [3] Richard D. Riley, Joie Ensor, Kym I. E. Snell и др. «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368 (2020), с. m441. DOI: 10.1136/bmj.m441.
- [4] Shachar Kaufman и др. «Leakage in data mining: formulation, detection, and avoidance». В: *ACM Transactions on Knowledge Discovery from Data* 6.4 (2012), с. 15. DOI: 10.1145/2382577.2382579.
- [5] Stephen B. Edge и Carolyn C. Compton. «The American Joint Committee on Cancer: the 7th edition of the AJCC cancer staging manual and the future of TNM». В: *Annals of Surgical Oncology* 17.6 (2010), с. 1471–1474. DOI: 10.1245/s10434-010-0985-4.
- [6] PyRadiomics community. *PyRadiomics documentation: radiomic features and customization of extraction*. 2025. URL: <https://pyradiomics.readthedocs.io>.

Словарь переменных и решений

Приведены все клинические и служебные переменные исходной таблицы, число узлов, вычисленная доза за фракцию, исход и оставленные радиомические признаки первичной опухоли (16 из 107) с числом исключённых признаков, которые каждый из них заменяет. Радиомические признаки лимфоузлов исключены целиком и в словаре не приводятся. Пропуски указаны после исправления значений во всей таблице (298 пациентов) и в аналитической когорте (140 пациентов). Момент доступности дан относительно применения модели после утверждения плана лечения.

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Patient_ID	код пациента, присвоенный при анонимизации, совпадает с именем папки снимков	целый, 1–315, уникален	служебная, всегда	0 / 0	оставить как ключ строки, не признак: идентификатор не несёт клинической информации
Fold	часть набора соревнования	категориальный: Training, Test	служебная, задана организаторами	0 / 0	исключить: служебная переменная
Local_tumor_recurrence	локальный рецидив первичной опухоли за период наблюдения	бинарный: 0, 1	после наблюдения не менее 2 лет	158 (53,0 %) / 0	исключить из признаков: источник целевой переменной
Gender	пол	категориальный: Male, Female	до начала лечения, при постановке диагноза	0 / 0	оставить
Age_at_diagnosis	возраст на момент диагноза, лет	целый, 30–89	до начала лечения, при постановке диагноза	0 / 0	оставить, заменяет 0 исключённых признаков
Race	раса	категориальный: White, Black, Hispanic, Asian, American_Indian/Alaska_Native	до начала лечения, при постановке диагноза	1 (0,3 %) / 0	оставить, пустая ячейка — пропуск, не заполнять
Tumor_side	латеральность опухоли	категориальный: L, R, Bilateral	до начала лечения, после стадирования	0 / 0	оставить
Tumor_subsite	подобласть ротоглотки	категориальный: BOT, Tonsil, GPS, Soft_palate, Pharyngeal_wall, Other	до начала лечения, после стадирования	0 / 0	оставить
T_category	категория T (AJCC 7)	порядковый: 1–4	до начала лечения, после стадирования	0 / 0	оставить
N_category	категория N (AJCC 7)	порядковый: 0, 1, 2a, 2b, 2c, 3	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить, служебный код X (1 значение) заменён пропуском
AJCC_Stage	стадия по AJCC 7, определяется T и N при M0	порядковый: I–IV	до начала лечения, после стадирования	1 (0,3 %) / 0	оставить, X (1) заменён пропуском, III при T4N1 (1) исправлено на IV
Pathological_grade	степень дифференцировки опухоли	порядковый: I, I-II, II, II-III, III, IV	до начала лечения, по биопсии	43 (14,4 %) / 16 (11,4 %)	оставить, пропуски не заполнять, доля ниже порога 30 %
Smoking_status_at_diagnosis	статус курения на момент диагноза	категориальный: Never, Former, Current	до начала лечения, при постановке диагноза	0 / 0	оставить

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
Smoking_Pack-Years	кумулятивное курение, пачко-лет	непрерывный, ≥ 0 , 0 только при Never	до начала лечения, при постановке диагноза	21 (7,0 %) / 10 (7,1 %)	оставить, 7 нулей при Current/Former заменены пропуском, заменяет 0 исключённых признаков
Radiation_treatment_course_duration	фактическая длительность курса ЛТ, дни	целый, 32–56	после окончания ЛТ	0 / 0	исключить: неизвестна в момент применения модели
Total_prescribed_Radiation_treatment_dose	суммарная предписанная доза, Гр	целый: 60, 63, 66, 70, 72	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить, заменяет 0 исключённых признаков
#_Radiation_treatment_fractions	число фракций	целый, 30–40	до начала ЛТ, при утверждении плана лечения	0 / 0	исключить: избыточна, $ \rho > 0,7$ с Dose_per_fraction
Induction_Chemotherapy	индукционная химиотерапия до ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
Concurrent_chemotherapy	химиотерапия одновременно с ЛТ	бинарный: Y, N	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить
KM_Overall_survival_censor	жизненный статус на последнем наблюдении	бинарный: 1 — жив, 0 — умер	после наблюдения	0 / 0	исключить: альтернативный исход, известен в обеих частях набора, но без времени наблюдения, неизвестен в момент применения модели
GTVn_n_nodes	число поражённых лимфоузлов, выделенных на маске GTVn	целый, 0–16	до начала лечения, по диагностической КТ	0 / 0	исключить вместе со всеми признаками GTVn: по условиям соревнования модель строится по первичной опухоли
Dose_per_fraction	вычисленная: доза на фракцию, Гр (доза / число фракций)	непрерывный, 1,8–2,4	до начала ЛТ, при утверждении плана лечения	0 / 0	оставить, заменяет 1 исключённый признак
Target_local_recurrence	целевая: 1 — локальный рецидив, 0 — нет	бинарный: 0 (128), 1 (12)	после наблюдения не менее 2 лет	158 (53,0 %) / 0	целевая переменная
GTVp_shape_MeshVolume	объём по треугольной сетке (GTVp)	непрерывный, мм^3 , > 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 23 исключённых признака
GTVp_shape_Sphericity	сферичность (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_shape_Elongation	вытянутость: отношение второй главной оси к первой (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_shape_Flatness	уплощённость: отношение третьей главной оси к первой (GTVp)	непрерывный, (0, 1]	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков

Продолжение на следующей странице

Переменная	Смысл	Тип, допустимые значения	Момент доступности	Пропуски (298 / 140)	Решение и комментарий
GTVp_firstorder_10Percentile	10-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак
GTVp_firstorder_90Percentile	90-й перцентиль плотности (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 2 исключённых признака
GTVp_firstorder_Entropy	энтропия гистограммы плотностей (GTVp)	непрерывный, бит, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 26 исключённых признаков
GTVp_firstorder_Kurtosis	эксцесс распределения плотностей (GTVp)	непрерывный, ≥ 1	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 3 исключённых признака
GTVp_firstorder_Maximum	максимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_firstorder_Minimum	минимальная плотность (GTVp)	непрерывный, HU	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 25 исключённых признаков
GTVp_glcm_Correlation	GLCM: корреляция уровней соседних вокселей (GTVp)	непрерывный, $[-1, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 4 исключённых признака
GTVp_glcm_InverseVariance	GLCM: обратная дисперсия (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков
GTVp_gldm_DependenceNonUniformityNormalized	GLDM: нормированная неоднородность зависимостей (GTVp)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 5 исключённых признаков
GTVp_glszm_SizeZoneNonUniformityNormalized	GLSZM: нормированная неоднородность размеров зон (GTVp)	непрерывный, $(0, 1]$	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак
GTVp_ngtdm_Busyness	NGTDM: «занятость» — частота смены тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 1 исключённый признак
GTVp_ngtdm_Contrast	NGTDM: контраст соседних тонов (GTVp)	непрерывный, ≥ 0	до начала лечения, по диагностической КТ	0 / 0	оставить, заменяет 0 исключённых признаков

Таблица 1: Словарь переменных и решений первичного анализа.