Материалы и методы

Разделение данных

Аналитическая таблица (140 пациентов, 12 с рецидивом) разделена на обучающую и тестовую выборки стратифицированно по исходу с фиксированным начальным значением генератора случайных чисел, поэтому при повторном запуске получаются те же выборки [1]. Стратификация нужна потому, что при 12 событиях случайное разделение могло бы оставить в тестовой выборке одно событие или ни одного. В тестовую выборку отведена четверть пациентов: 35, из них 3 с рецидивом. В обучающую вошли 105 пациентов, из них 9 с рецидивом. Большая доля теста сократила бы и без того малое число событий для обучения [2], а меньшая оставила бы для итоговой оценки однодва события.

Тестовая выборка будет использована один раз, для итоговой оценки выбранной модели. Подбор моделей и их параметров будет выполняться перекрёстной проверкой внутри обучающей выборки. Дополнительной внешней проверкой станут предсказания для 158 пациентов тестовой части соревнования на Kaggle [3]. Все величины для подготовки признаков (значения для заполнения пропусков, перечень логарифмируемых признаков, сдвиг и масштаб, категории для кодирования) вычислены только по обучающей выборке без использования исхода и без пересчёта применены к тестовой.

Подготовка признаков

В обучающей выборке пропусков нет у 79 из 105 пациентов. Степень дифференцировки пропущена у 13 пациентов, пачко-годы у 9, минимальная плотность у 5, а ещё 11 признаков плотности и текстуры — у одного пациента, у которого они удалены из-за металла в маске опухоли. Исключение пациентов с пропусками сократило бы выборку на четверть, поэтому пропуски заполнены. Все пропуски пачко-лет приходятся на курящих и бывших курильщиков, и они заполнены медианой среди курильщиков обучающей выборки (26 пачко-лет): общая медиана была бы занижена некурящими с нулевым значением. Степень дифференцировки заполнена медианой порядкового кода (III). Отсутствие оценки само может нести сведения о биопсийном материале, поэтому добавлен признак-индикатор пропуска. Радиомические признаки заполнены медианами обучающей выборки, так как медиана устойчива к асимметрии распределений.

Выбросы в каждом количественном признаке обучающей выборки определялись по правилу полутора межквартильных размахов. Они найдены у 17 из 20 признаков, больше всего у дозы за фракцию (20), максимальной плотности (11), «занятости» текстуры (busyness, 10) и объёма опухоли (9). Выбросы не удалялись и не усекались. Значения, невозможные для тканей, исправлены на этапе первичного анализа, а оставшиеся отражают реальные случаи: альтернативные схемы фракционирования и крупные опухоли. Их удаление сократило бы и без того малое число пациентов с рецидивом. Влияние выбросов ослаблено логарифмированием восьми признаков с правой асимметрией больше 1 и неотрицательными значениями: $\ln x$ для строго положительных и $\ln(1 + x)$ для пачко-лет, где есть нули. Логарифм $\ln(1 + x)$ для признаков со значениями порядка сотых почти не меняет распределение, поэтому для них взят $\ln x$. После логарифмирования выбросов не осталось в объёме опухоли, пачко-годах и «занятости» текстуры, а в максимальной плотности их стало 1 вместо 11. Признаки с левой асимметрией, например 10-й перцентиль плотности, логарифмированию не подлежат и сохранены как есть.

Количественные признаки нормализованы вычитанием среднего и делением на стандартное отклонение обучающей выборки (z-нормализация). Далее планируются модели с регуляризацией, штраф которых зависит от масштаба признаков, поэтому признаки приведены к сопоставимому масштабу. После логарифмирования распределения ближе к симметричным, и среднее со стандартным отклонением описывают их более чем удовлетворительно. Так же нормализованы порядковые коды.

Бинарные признаки (пол, индукционная и одновременная химиотерапия) закодированы значениями 0 и 1. Порядковые признаки закодированы рангами, сохраняющими порядок: категория T — от 1 до 4, категория N (0, 1, 2a, 2b, 2c, 3) — от 0 до 5, стадия — от 1 до 4, степень дифференцировки (I, I–II, II, II–III, III, IV) — значениями 1; 1,5; 2; 2,5; 3; 4. Прямое кодирование отдельными столбцами потеряло бы порядок и добавило бы признаков при малом числе событий. Номинальные признаки (раса, сторона и подобласть опухоли, статус курения) закодированы бинарными столбцами для каждой категории, кроме опорной (One-Hot-Encoding), самой частой в обучающей выборке: европеоидная раса, левая сторона, корень языка, бывший курильщик. Опорная категория исключена, чтобы столбцы не были линейно зависимы. Категории, встречающиеся в обучающей выборке реже 5 раз, объединены, так как отдельный столбец для 1–3 пациентов даёт неустойчи-

вую оценку. Так, негроидная и латиноамериканская расы объединены в другую расу, а мягкое нёбо и стенка глотки отнесены к другой подобласти. Категории, отсутствующие в обучающей выборке, при кодировании тестовой выборки также относятся к другой.

В итоге подготовленные выборки содержат 35 признаков: 20 количественных, 4 порядковых, индикатор пропуска степени дифференцировки, 3 бинарных и 7 бинарных столбцов номинальных признаков. Пропусков не осталось, все признаки числовые.

Ссылки

[1] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort и др. «Scikit-learn: Machine Learning in Python». В: *Journal of Machine Learning Research* 12 (2011), с. 2825–2830.

[2] Richard D. Riley, Joie Ensor, Kym I. E. Snell и др. «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368 (2020), с. m441. DOI: 10.1136/bmj.m441.

[3] Amber Simpson и др. *Oropharynx Cancer (OPC) Radiomics Challenge :: Local Recurrence Prediction*. https://www.kaggle.com/competitions/opc-recurrence. Kaggle. 2016.