Материалы и методы

Модели машинного обучения

Для прогнозирования локального рецидива рака ротоглотки по клиническим и КТ-радиомическим признакам обучены логистическая регрессия, дерево решений и случайный лес в библиотеке scikit-learn версии 1.9.1 [1]. Логистическая регрессия выбрана как линейная модель с регуляризацией: при малом числе рецидивов ограничение величины коэффициентов снижает риск подгонки к отдельным пациентам. Использован квадратичный штраф с обратной силой регуляризации 0,1. Дерево решений позволяет учесть пороговые зависимости и взаимодействия клинических и радиомических характеристик. Для ограничения сложности максимальная глубина дерева ограничена значением 3, а лист содержал не менее 8 обучающих пациентов. Случайный лес из 300 деревьев выбран как ансамбль, усредняющий нестабильные решения отдельных деревьев [2]. Глубина его деревьев также ограничена значением 3, минимальное число пациентов в листе составляет 5; при поиске разбиения рассматривается случайный набор признаков размером с квадратный корень из их числа. Из-за редкости рецидива во всех моделях использованы веса классов, обратно пропорциональные их частотам; для леса они рассчитаны отдельно в каждой бутстреп-выборке. Настройки заданы до сравнения на валидации и по её результатам не менялись.

Обучение и сравнение моделей

Использована аналитическая таблица недели 4: 140 пациентов, 12 с рецидивом, 31 исходный признак. Сохранены идентификаторы тестовой выборки недели 5: 35 пациентов, из них 3 с исходом 1. Из оставшихся 105 пациентов стратифицированным по исходу случайным разделением выделена валидационная выборка объёмом 20%: 21 пациент, 2 с рецидивом. Обучающая выборка содержит 84 пациента, 7 с рецидивом. Стратификация сохраняет представительство редкого исхода, а небольшая валидационная доля оставляет больше событий для обучения [3]. Для разделения и стохастических моделей зафиксировано начальное значение генератора 42; состав выборок проверен на отсутствие пересечений. Распределение исхода показано на рис. 1.

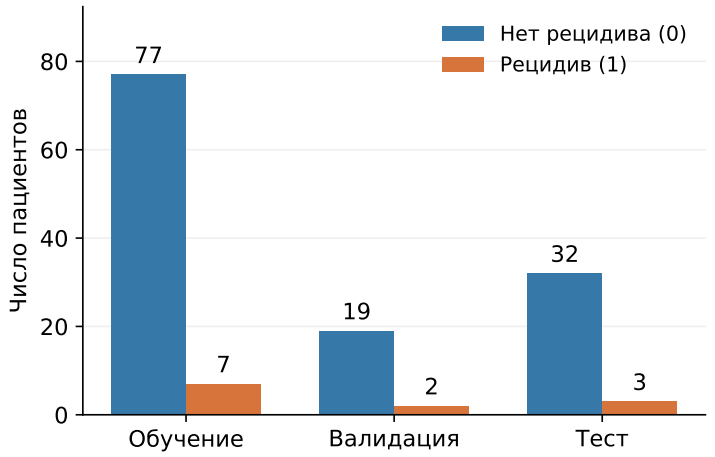


Рис. 1: Число пациентов с рецидивом и без рецидива в каждой выборке.

Подготовка признаков включена в каждую модель и заново настроена только по 84 обучающим пациентам: готовые преобразованные таблицы недели 5 не использованы, поскольку их параметры рассчитаны также по будущей валидационной выборке. Пропуски 20 количественных и 4 порядковых признаков заполнены обучающими медианами. После заполнения у 15 количественных признаков найдены выбросы по правилу полутора межквартильных размахов; эти признаки нормализованы по обучающим медиане и межквартильному размаху. Для остальных 5 количественных признаков и порядковых кодов использованы обучающие среднее и стандартное отклонение. Медиана и межквартильный размах устойчивы к крайним значениям; сопоставимый масштаб нужен для регуляризации. Выбор метода и параметры не пересчитывались на валидации. Количественные признаки не логарифмировались: для этого сравнения сохранена единая простая подготовка без дополнительного подбора преобразований при семи событиях. Порядковые коды сохраняют порядок при малой размерности, но для линейных и метрических моделей предполагают равноценность одинаковых числовых шагов, хотя клинический эффект переходов может различаться. Rank-Hot также сохраняет порядок с помощью нескольких пороговых индикаторов. Три бинарных признака представлены нулями и единицами. Пропуски категориальных признаков заполнены обучающими модами. Четыре номинальных признака закодированы индикаторами с исключением одной опорной категории; категории с частотой менее 5 объединены для уменьшения числа неустойчивых оценок. Неизвестные категории валидации отнесены к редкой группе, если она сформирована, иначе представлены нулями. Добавлен индикатор пропуска степени дифференцировки, так как отсутствие оценки может характеризовать доступность биопсий-

ного материала. Получено 36 числовых признаков; параметры без пересчёта применены к валидации.

Основная мера сравнения — доля верных ответов на валидационной выборке; та же мера на обучении приведена для оценки подгонки. Из-за дисбаланса дополнительно рассчитаны чувствительность, средняя полнота двух классов и матрицы ошибок, а ориентиром служит постоянный прогноз отсутствия рецидива. Сравнение точности приведено на рис. 2, структура ошибок — на рис. 3. При двух событиях валидации оценки неустойчивы, поэтому высокая доля верных ответов сама по себе не подтверждает способность выявлять рецидив. Тестовая выборка не использована для настройки подготовки, обучения, предсказаний и сравнения моделей; она отложена для однократной итоговой оценки после фиксации модели.

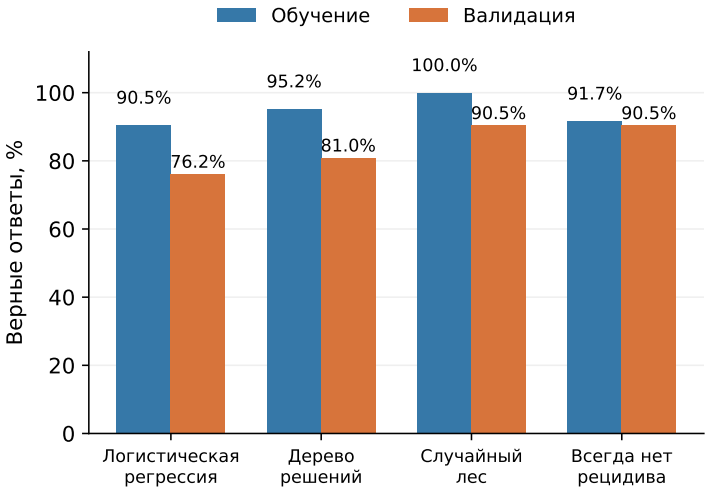


Рис. 2: Доля верных ответов на обучающей и валидационной выборках для трёх моделей и постоянного прогноза отсутствия рецидива.

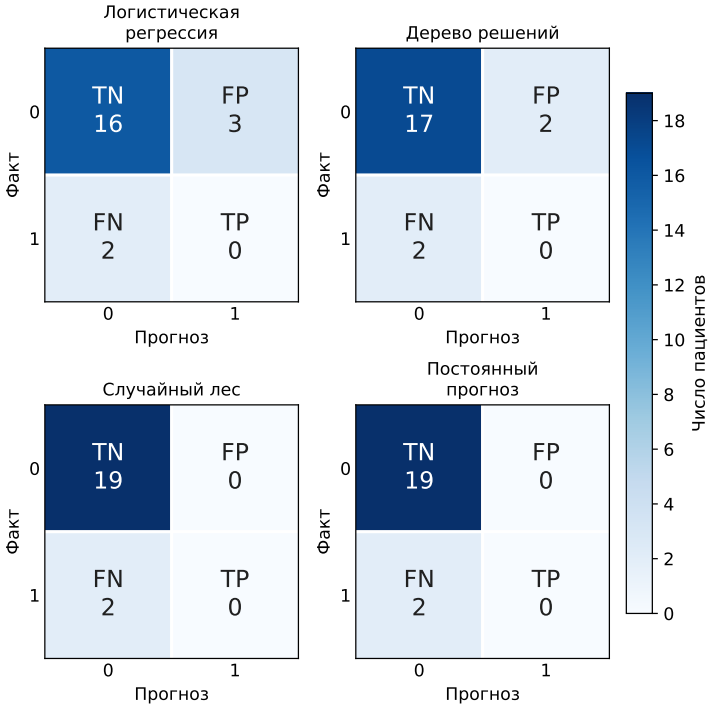


Рис. 3: Матрицы ошибок на валидации ($n = 21$): строки — фактический класс, столбцы — предсказанный; 0 — отсутствие рецидива, 1 — рецидив. Цветовая шкала общая.

Ссылки

[1] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort и др. «Scikit-learn: Machine Learning in Python». В: *Journal of Machine Learning Research* 12 (2011), с. 2825–2830. URL: https://jmlr.org/papers/v12/pedregosa11a.html.

[2] Leo Breiman. «Random Forests». В: *Machine Learning* 45 (2001), с. 5–32. DOI: 10.1023/A:1010933404324.

[3] Richard D. Riley, Joie Ensor, Kym I. E. Snell и др. «Calculating the sample size required for developing a clinical prediction model». В: *BMJ* 368 (2020), с. m441. DOI: 10.1136/bmj.m441.